

Reliable and Trustworthy AI — Assignment #3

Marabou를 이용한 신경망 지역 견고성 검증

Assignment #3 | 2026년 5월

1. 모델 및 데이터셋

본 과제에서는 MNIST 손글씨 숫자 데이터셋에 대해 훈련된 소형 완전연결 신경망(MLP)을 사용하였다. Marabou의 기본 제공 resources 디렉터리에 포함된 모델과 중복되지 않도록 직접 설계·훈련한 외부 모델이다.

모델 구조:	784 -> 64 -> 32 -> 10 (ReLU, 선형 출력)
활성화 함수:	ReLU (Marabou가 최적 지원)
데이터셋:	MNIST (torchvision, 테스트 10,000개)
테스트 정확도:	96.35 %
모델 포맷:	ONNX (opset 14, 고정 배치 크기 1)

ReLU 활성화 함수를 선택한 이유는 Marabou가 ReLU 네트워크에 대해 완전한 SMT 기반 검증을 지원하기 때문이다. 모델 크기는 784→64→32→10으로 설정해 검증 시간을 현실적인 범위 (수 분 이내)로 제한하였다.

2. 검증 쿼리

지역 견고성(Local Robustness) 쿼리를 정식화하였다. 테스트 입력 x 가 참 레이블 d 로 분류될 때, ℓ_∞ 공(ball) 내의 모든 perturbation x' 도 동일한 클래스 d 로 분류되는지 검증한다.

샘플 인덱스:	0
참 레이블:	digit 7
perturbation 반경 ϵ :	0.01
검증 모드:	전체 9개 클래스 (--full)

입력 제약: 각 픽셀 i 에 대해 $\max(0, x_i - \epsilon) \leq x'_i \leq \min(1, x_i + \epsilon)$.

출력 제약: 경쟁 클래스 $j \neq d$ 에 대해 $\text{output}[j] - \text{output}[d] \geq 0$ (SAT 질의).

모든 j 에 대해 UNSAT이면 지역 견고성이 형식적으로 보장된다.

3. 실험 결과 및 해석

검증 결과:	UNSAT (견고성 검증 성공)
소요 시간:	0.95 초

모든 9개 경쟁 클래스(digit 0-6, 8-9)에 대한 하위 쿼리가 UNSAT으로 판정되었다. 즉, $\epsilon = 0.01$ 범위의 ℓ_∞ 공 내에서는 어떠한 perturbation도 모델이 digit 7가 아닌 다른 클래스로 예측하도록 만들 수 없음이 형식적으로 증명되었다.

가장 높은 경쟁 로짓을 가진 클래스(digit 3, logit=3.41)부터 낮은 순서로 검증하였으며, 9개 쿼리 전체가 0.95초 이내에 완료되었다. 소형 MLP와 작은 ϵ 의 조합이 실용적인 검증 시간을 가능하게 한다.

4. Marabou 장단점 분석

장점

- 형식적 보장: SMT 기반으로 SAT/UNSAT 결과가 수학적으로 완전하다.
- ONNX 지원: PyTorch 등 주요 프레임워크에서 훈련한 모델을 직접 사용할 수 있다.
- Python API(maraboupy): 검증 쿼리를 코드로 유연하게 정의할 수 있다.
- 다양한 속성 지원: 견고성, 안전성, 도달 가능성 등 폭넓은 검증 유형을 처리한다.

Reliable and Trustworthy AI — Assignment #3

단점 및 한계

- 확장성 제한: ReLU 뉴런 수가 늘어날수록 지수적으로 검증 시간이 증가한다. 실용적으로는 수백~수천 뉴런 규모에 그친다.
- 설치 복잡성: Python 3.12 이상 미지원(≤ 3.12 제약), C++ 컴파일 필요, Windows 네이티브 미지원 등 환경 설정이 까다롭다.
- 동적 아키텍처 미지원: 순환 신경망(RNN), Transformer 등 동적 구조는 검증 불가.
- 실수 연산 근사: 부동소수점 오차가 누적될 경우 결과의 신뢰성에 영향을 줄 수 있다.

종합하면, Marabou는 소규모 안전 필수 신경망(예: ACAS Xu 충돌 방지 시스템)의 공식 검증에 적합하다. 대규모 현대 모델에는 추상 해석(Abstract Interpretation) 기반 도구 등 더 확장성 있는 접근이 필요하다.